📘 反思智能規範（Reflection Intelligence Specification, RIS）v2.0

反思智能標準化文件
作者：Danny Ko
年份：2025

文件狀態（Status of This Document）

反思智能規範（RIS）v2.0 為主要版本升級（**major version release**），全面取代所有 RIS v1.x 文件。

本規範定義了可實際部署、具生產等級（**production-grade**）的反思智能（**Reflection Intelligence, RI**）完整架構，內容包含：強制性的反思記憶、正式的收斂與終止保證、安全反思機制、標準化評估指標，以及具約束力的反思邊界與權限模型（**RBAM**）。

RIS v2.0 為具規範性（**normative**）的標準文件。任何宣稱符合 *RIS v2.0* 的系統，必須（**MUST**）滿足本文件中所定義的所有強制性要求。

---

1. 規範範圍（Scope）

RIS v2.0 定義以下內容：

- 反思智能（RI）的正式定義
- 擴充後的多層 RI 架構
- 強制性反思記憶（Reflection Memory, RM v2.0）
- 安全反思層（Safety Reflection Layer, SRL）
- 反思品質分數（Reflection Quality Score, RQS v2.0）
- 推理完整性指標（Reasoning Integrity Metric, RIM v2.0）
- 擴充錯誤分類標準（Error Taxonomy Standard, ETS v2.0）
- 條件式與自適應反思循環協議（RLP v2.0）
- 正式的收斂與終止保證
- 反思邊界與權限模型（RBAM）
- 透明性、可審計性與合規要求

RIS v2.0 不規範 底層模型的實作方式，而是明確規範 **RI** 相容系統在行為、結構與評估層級上必須遵守的限制與責任。

2. 反思智能的定義（Definition of Reflection Intelligence）

反思智能（**Reflection Intelligence, RI**）是一套元認知推理框架，透過在前向推理之後引入結構化的**反思（Reflection）、分析（Analysis）與強化（Reinforcement）**循環，使系統能夠：

- 檢視自身推理過程
- 揭露隱含假設與不確定性
- 診斷推理結構性錯誤
- 生成經修正的改良推理結果
- 展現可量化、可驗證的推理品質提升

在形式上，RI 將推理從一次性前向函數，轉化為可自我修正、可審計的推理流程。

---

3. RI v2.0 架構概述（Architectural Overview）

所有 RI 相容系統 必須（**MUST**）實作以下層級：

1. 前置推理協議（Pre-Reasoning Protocol, PRP）— 第 0 層
2. 反思層（Reflection Layer, RL）
3. 分析層（Analysis Layer, AL）
4. 強化層（Reinforcement Layer, ReL）
5. 反思記憶（Reflection Memory, RM）
6. 安全反思層（Safety Reflection Layer, SRL）

執行流程（Execution Flow）

- 輸入 → PRP → 初始輸出（IO_1）
- → RL → 反思狀態（RS）
- → AL → 分析輸出（AO）
- → SRL 驗證
- → ReL → 改善後輸出（IO_2）
- → RM 更新
- →（條件式循環）

4. 前置推理協議（PRP）— 第 0 層

在進行任何推理之前，系統 必須（**MUST**）初始化以下認知約束：

- 認知謙卑（Epistemic Humility）
- 多視角意識（Multi-perspective Awareness）
- 假設透明（Assumption Transparency）
- 情境定位（Contextual Grounding）
- 認知平衡（Cognitive Balance）
- 價值中立立場（Value-neutral Stance）

PRP 用以建立推理姿態（**reasoning posture**），並約束後續所有推理與反思行為。

---

5. 反思層（Reflection Layer, RL）規範

反思層 必須（**MUST**）：

- 檢查推理的連貫性
- 識別邏輯缺口與跳步
- 揭露隱含假設
- 偵測不確定性指標
- 評估推理完整性

反思狀態（Reflection State, RS v2.0）

RS 必須（**MUST**）為決定性（deterministic）且可機器讀取。

最低必備欄位：

- coherence_report（連貫性報告）
- assumption_list（假設列表）
- logical_consistency_report（邏輯一致性報告）
- completeness_report（完整性報告）
- uncertainty_profile（不確定性描述）
- coverage_score ∈ [0, 1]

6. 分析層（Analysis Layer, AL）規範

分析層 必須（**MUST**）：

- 將 RS 轉換為結構化問題
- 套用 ETS v2.0 進行分類
- 指派錯誤嚴重度
- 產生明確的修正策略

分析輸出（Analysis Output, AO v2.0）

AO 必須（**MUST**）包含：

- error_type（錯誤類型）
- subcategory（子類別）
- severity（嚴重度，1–3）
- diagnostic_description（診斷說明）
- recommended_fix（建議修正）
- expected_impact（預期影響）

AO 必須（**MUST**）可被審計與重現。

7. 強化層（Reinforcement Layer, ReL）規範

強化層 必須（**MUST**）：

- 依 AO 指示套用修正
- 必要時重新生成推理鏈
- 保留有效且正確的既有推理
- 產生改善後輸出（IO□）

改善要求（Improvement Requirement）

- Q(IO□) > Q(IO□$_{-1}$)

其中 **Q** 由 **RQS v2.0** 定義。

8. 反思記憶（Reflection Memory, RM v2.0）

反思記憶在 RIS v2.0 中為**強制（MANDATORY）**組件。

RM 必須（**MUST**）：

- 持久化儲存 RS 與 AO
- 支援相似度導向的擷取
- 提供版本管理與衰減機制
- 防止低信心反思被持續放大

RM 不得（**MUST NOT**）：

- 強化已劣化的推理
- 儲存被 SRL 否決的產物

9. 安全反思層（Safety Reflection Layer, SRL）

SRL 為**硬性安全閘門（hard safety gate）**與監督權限。

SRL 必須（**MUST**）：

- 偵測幻覺式修正
- 偵測推理品質劣化
- 偵測失控的反思循環
- 在出現安全或權限風險時覆寫 AO

SRL 可以（**MAY**）提前終止反思流程。

10. 錯誤分類標準（ETS v2.0）

強制性主要類別：

1. 邏輯錯誤（LE）
2. 事實錯誤（FE）
3. 假設錯誤（AE）
4. 範疇錯誤（SE）
5. 推理結構錯誤（RSE）
6. 安全與對齊錯誤（SAE）
7. 記憶污染錯誤（MCE）

所有錯誤 必須（**MUST**）標示嚴重度。

11. 反思品質分數（Reflection Quality Score, RQS v2.0）

RQS 用於衡量輸出品質的實際改善程度。

- $RQS = w_1 \cdot Coverage + w_2 \cdot Rigor + w_3 \cdot CorrectionEffectiveness + w_4 \cdot Stability$

所有分量皆介於 [0, 1]。

12. 推理完整性指標（Reasoning Integrity Metric, RIM v2.0）

RIM 用於評估推理過程本身的品質，與結論是否正確無關。

評估面向包含：

- 結構完整性
- 邏輯連續性
- 假設透明度
- 約束遵循性

13. 反思循環協議（Reflection Loop Protocol, RLP v2.0）

反思行為為條件式且自適應。

當符合以下任一條件時，反思 必須（**MUST**）終止：

- RQS 改善幅度 $< \varepsilon$
- RIM 趨於穩定
- 達到最大反思次數
- SRL 觸發安全或權限終止

14. 收斂保證（Convergence Guarantees）

RIS v2.0 要求（**REQUIRES**）：

- RQS 單調不下降
- 反思循環次數有上界
- 防止震盪式或退化式修正

15. 透明性與可審計性（Transparency & Auditability）

RI v2.0 系統 必須（**MUST**）：

- 揭露 RS、AO 與修訂歷史
- 揭露權限領域標註（依 RBAM）
- 支援第三方審計
- 防止隱藏推理步驟

16. 反思邊界與權限模型（Reflection Boundary & Authority Model, RBAM）

所有 RIS v2.0 系統 必須（**MUST**）實作 **RBAM**，作為反思行為的最高約束模型。

RBAM 明確定義：

- 權限領域（IA / RA / KA / SPA）
- 權限覆寫階層
- 實質修改輸入權限（SM-IA）
- 安全反思層（SRL）的最終裁決權
- 明確禁止的反思行為
- 強制性的審計要求

RBAM 規範 **RI** 可以修改什麼、不得修改什麼，以及最終裁決權歸屬。

任何違反 RBAM 的行為，必須（**MUST**）被視為不合規。

17. 合規要求（Compliance Requirements）

系統僅在符合以下所有條件時，方可宣稱 **RIS v2.0** 合規：

1. 完整實作所有強制層級（PRP、RL、AL、ReL、RM、SRL）
2. 無例外地執行 RBAM
3. 使用 ETS v2.0
4. 計算並揭露 RQS 與 RIM
5. 展現可測量的推理品質提升
6. 支援完整透明與審計

18. 附錄：形式化運算子（Formal Operators）

反思（**Reflection**）

- R: IO → RS

分析（**Analysis**）

- A: RS → AO

強化（**Reinforcement**）

- I: (IO, AO, RM) → IO'

品質函數（**Quality**）

- Q: IO → ℝ

反思智能規範（**RIS**）**v2.0**（中文版）文件結束